

[ABSTRACT]

1. Introducción

1.1 Contexto General

Los refugios de animales son unos de los varios sectores de hoy en día en donde manejan constantemente grandes volúmenes de información asociada a los animales bajo su cuidado, incluyendo variables demográficas y morfológicas: raza, edad, sexo, coloración, estado de salud, comportamiento, historial de ingreso y resultado del proceso de adopción. Gracias a la gran variación de los datos manejados nos abre la posibilidad de utilizar las técnicas de análisis estadístico y aprendizaje automático para transformar los registros operativos en información predictiva, la cual nos ayudará a la toma de decisiones.

De hecho, ya existen iniciativas como es ‘Shelter Animal Count’, las cuales analizan datos de refugios a nivel nacional y desde el 2024. Shelter Animal Count, ya emplea un modelo de aprendizaje automático para generar estimaciones precisas de sus datos utilizando variables del animal. Gracias a todo esto existe la posibilidad de identificar patrones y apoyar a la toma de decisiones [1].

Así mismo, ya existen otro tipo de modelos que estiman las características de un animal a partir de datos disponibles, reduciendo la necesidad de realizar mediciones manuales. De hecho, Amir Zadeh, y colaboradores. enfocaron un análisis de estudio en donde implementaron redes neuronales, y árboles de decisión junto con otro tipos de técnicas de minería de datos, todo esto para predecir la velocidad de adopción. Esto fue gracias a la relación que existía entre

la edad, raza, cantidades de publicación y el estado de esterilización, por lo que se dieron cuenta que dichas variables eran los factores que contribuyen más a la adopción de una mascota [2].

El trabajo de este documento, es similar al análisis proporcionado por el equipo de Amir y colaboradores. En donde el enfoque principal es el peso del perro y ver la correlación que existe con los otros factores.

1.2 Descripción del dataset

En este caso se está utilizando el dataset de “Dog_Adoption_Master.csv”, el cual fue proporcionado por la plataforma Kaggle. En este caso el dataset contiene alrededor de 42,000 instancias de perros que pasaron por el proceso de adopción dentro de un refugio, descritos por 32 atributos. Los atributos pueden ser agrupados en tres tipos: (1) Características físicas del perro (edad, peso, tamaño, grupo de raza, tipo de ingreso al refugio, necesidades médicas. (2) Rasgos de comportamiento (nivel de agresividad, ansiedad por separación, reactividad hacia otros perros, nivel de energía, nivel de entrenamiento.). Cabe mencionar, que las agrupaciones de nivel 2 (Rasgos de comportamiento, son medidas del 0 - 10. Indicando que el 0 es el nivel más bajo de la categoría y 10 el más alto. (3) Información sobre el proceso de adopción y el hogar adoptante. (Tipo de vivienda, presencia de niños o mascotas, número de visitas antes de la adopción y si el perro fue devuelto al refugio.). En la siguiente tabla se puede observar la información detallada de cada uno de los

features incluyendo una descripción corta y el tipo de dato que es.

Variable	Tipo	Descripción
Adoption_id	Texto	Identificador único del registro de adopción
Age_years	Numérica	Edad del perro, en años.
Size	Categórica	Categoría de tamaño (Small, medium, large, xlarge)
Weight_in_kg	Numérica	Peso del perro, en kg
Breed_group	Categórica	Grupo de raza (Hound, terrier, herding, mixed, sporting, toy, working)
Intake_type	Categórica	Forma de ingreso al refugio (stary, Owner_surrender, transfer, born_in_care)
Days_in_shelter	Numérica	Días que el perro permaneció en el refugio antes de ser adoptado.
Previously_returned	Categórica	Nivel de necesidades médicas (None, Minor, Chronic)
Neutered	Binaria	Si el perro está esterilizado.
Agression_score	Numérica	Agresividad, escala 0-10.
Anxiety_separation	Numérica	Ansiedad por separación, escala 0-10.
Reactivity_to_dogs	Numérica	Reactividad hacia otros perros, escala 0-10
Energy_level	Numérica	Nivel de energía, escala 0-10

Training_level	Numérica	Nivel de obediencia, escala 0-10
House_trained	Binaria	Si el perro está entrenado para estar dentro de casa
First_time_owner	Binaria	Si el adoptante es dueño de perros por primera vez
Household_has_kids	Binaria	Si hay niños en el hogar del adoptante.
Household_has_pets	Binaria	Si hay otras mascotas en el hogar del adoptante.
Home_type	Categórica	Tipo de vivienda del adoptante.
Has_yard	Binaria	Si el hogar del adoptante tiene patio.
Hours_alone_per_day	Numérica	Horas promedio que el perro estaría solo al día.
Adopter_activity_level	Numérica	Nivel de actividad física del adoptante
Visits_before_adoption	Numérica	Número de visitas al refugio antes de adoptar.
Met_resident_pets	Binaria	Si el perro convivió con las mascotas del adoptante.
Adoption_counseling	Binaria	Si el adoptante recibió asesoría antes de adoptar
Expectation_score	Numérica	Qué tan alineadas estaban las expectativas del adoptante.
Energy_mismatch	Numérica	Diferencia entre la energía del perro y la del adoptante.
Size_home_mismatch	Binaria	Posible desajuste entre tamaño del perro y tipo de

		vivienda
Return_reason	Catagórica	Motivo de devolución, si aplica
Days_to_return	Numérica	Días hasta la devolución, si aplica
Returned	Binaria	Si el perro fue devuelto al refugio.

Tabla 1.1: “Tabla de variables del dataframe”

1.3 ¿Qué se está prediciendo?

En este trabajo nuestra variable objetivo es “**Weight_in_kg**”, en otras palabras el peso del perro en kilogramos. A pesar de esto, el proceso para elegir nuestra variable a predecir no resultó fácil debido a que al inicio mi hipótesis fue predecir la variable de “Days_in_shelter”(los días que tarda un perro en ser adoptado), esta fue mi variable objetivo al principio debido a que es una pregunta de negocio más interesante para un refugio, debido a que es una de las variables más importantes para los refugios dado que quieren que las mascotas encuentren un hogar lo más rápido posible. Sin embargo, durante el análisis exploratorio, se mostró que ninguna de las variables físicas ni de comportamiento disponibles tenían una correlación lineal apreciable con “Days_in_shelter”, cómo se va a apreciar posteriormente en la sección 3 (Análisis Exploratorio de Datos (EDA)). Todas las correlaciones con la variable de “Days_in_shelter” estaban por debajo de 0.05 en valor absoluto. Gracias a esto, se formó la decisión de no utilizar esta variable como mi variable objetivo debido a que este tipo de variables producen modelos que apenas aprenden, lo cual no demostraría que nuestro algoritmo funciona de la mejor manera. Como mencionan Kuhn y Johnson (2013), en “Applied Predictive Modeling” al retener variables con baja o correlaciones lineales nulas introducen ruido en lugar de señal predictiva. Por lo tanto, esto puede degradar la estabilidad del modelo y proporcionar un

aprendizaje deficiente. Debido al ruido que se está generando. [3]

Por otra parte, en “**Weight_in_kg**” muestra una correlación fuerte y clara con otra variable del dataset, el tamaño del perro (“**Size**”). Sin embargo, aunque parezca una variable no tan útil para los refugios, de hecho les ayuda bastante debido a que les permite a los refugios estimar dosis de medicamentos o proporciones de comida para los perros y también ayuda a crear una validación con los datos registrados en la base de datos del refugio, esto se debe a que a la gran escala y corto tiempo que existen en los refugios puede que haya errores en algunos de los datos. Gracias a que Weight_in_kg ayuda a señalar estadística real y existe utilidad práctica es por lo que se eligió weight_in_kg, como variable objetivo final del proyecto.

1.4 ¿Regresión o clasificación?

Para empezar un problema de regresión busca predecir una variable cuantitativa, es decir un valor numérico que puede tomar cualquier número dentro de un rango continuo. Por otra parte, un problema de clasificación lo que busca es predecir una variable categórica, ya sea predecir una variable categórica que pertenece a un conjunto finito, niveles de riesgo o tipos de clases. Es por eso, que la diferencia no está en el algoritmo que se utilice para resolver sino que está en lo que se quiere predecir, ya sea si la variable objetivo es numérica y continua, lo cual la haría de un problema de regresión, o si la variable es una categoría, lo hace un problema de clasificación. [4]

Gracias a esto podemos definir que nuestra variable de “Weight_in_kg” es una variable numérica continua (rango observado: 2.0 a 70.6 kg), es por eso que no es categórica debido a que es una variable numérica. Por lo tanto, es un problema de regresión. Si nuestra variable objetivo fuera “returned”, o sea si el perro fue devuelto al refugio 0 o 1, este sería

un problema de clasificación debido a que pertenece a dos tipos de clases en vez de ser un rango numérico continuo. Dado que el objetivo de nuestro modelo es estimar cuántos kilogramos pesa un perro, es por eso que se utiliza la regresión lineal y no la regresión logística ni ningún otro tipo de clasificador.

2. Extracción, Transformación y Carga de Datos (ETL)

2.1 ¿Qué es ETL?

ETL es un acrónimo de “Extract, Transformación y Carga de datos” es un proceso mediante el cual los datos se obtienen de una o varias fuentes, se limpian y transforman a un formato más analizable. Finalmente, se cargan en un destino en donde se pueden analizar o modelar. El ETL es un marco de trabajo estándar en cuanto a la ingeniería de datos esto es debido a que ayuda a preparar la información desde antes de cualquier análisis o entrenamiento de modelos. [5]. El ETL tradicionalmente se compone en tres etapas:

Extracción: Es en donde se obtienen los datos crudos desde la fuente original, en esta área no se hace ningún tipo de cambio a la data.

Transformación: Es en donde se limpian, validan y reestructuran los datos. También, es en donde se manejan los valores nulos, la eliminación de duplicados y la codificación de variables categóricas. Todo esto es para que los datos estén listos para proseguir con el área de análisis.

Carga: Es en donde se almacena el resultado final en un formato listo para ser consumido por las siguientes etapas del proyecto.

Aunque el ETL surgió para los datos empresariales, el mismo marco de tres etapas aplica directamente a cualquier proyecto de ciencias de datos, esto se debe a que ayuda a

tener un proceso en cuestión de los datos ya que, en muchos casos los datos no son consistentes, incluyen errores y tienen formatos diferentes causando inconsistencias dentro de los modelos. Es por eso la importancia de aplicar un ETL en cualquier modelo que se esté trabajando con datos, ya que ayuda a evitar muchos de estos problemas que pueden afectar la manera en la que funciona nuestro modelo. A continuación la sección 2.2 -2.6 documenta cómo se aplicó cada etapa del dataset en el proyecto.

2.2 Extracción

Dentro de la etapa de extracción, como mencionado en la sección 2.1, es en donde se obtienen los datos crudos desde la fuente original (Kaggle), esto sin aplicar ninguna transformación. En este proyecto los datos con los que estamos trabajando están en un archivo .csv llamado “dog_adoption_master.csv”, el cual contiene los registros históricos de adopciones de un refugio de perros.

Utilizando la librería de pandas se pudo extraer los datos. Gracias a pandas los tabula en un Dataframe, el cual nos ayuda a poder trabajar con la información de una manera más clara y sencilla.

Posteriormente después de la extracción se verificó que la carga fuera correcta utilizando los diferentes comandos como “df.shape, df.info() y df.head()”. Gracias a esto nos confirma que estamos trabajando con datos de 42,000 instancias y 32 atributos. No solo eso sino que, hay una mezcla de tipo de datos 12 atributos son float64, 13 son int64 y 7 son strings. Gracias a esta extracción podemos ver con qué datos estamos trabajando facilitando las siguientes etapas del proyecto.

2.2 Análisis y revisión de calidad de datos.

Gracias a la revisión descrita en la sección anterior se hicieron tres aspectos para

mejorar la calidad de los datos con los que estamos trabajando.

Para empezar la existencia de los valores nulos, dentro de nuestro dataframe existía un atributo de los 32, el cual contaba con 35,703 valores nulos, debido a que estamos trabajando con 42,000 instancias esto es el 85% de las instancias con datos nulos. El atributo que contaba con esto era “Days_to_return”, este es un atributo interesante debido a que solo aplica a los perros que fueron devueltos al refugio. En otras palabras, los valores nulos eran para los perros que no aplicaban. Es por eso que se tomó la decisión de cambiar los valores nulos a 0 para que pueda ser utilizado dentro de nuestro análisis, sin eliminar todo el atributo.

Por otra parte, se revisaron los valores duplicados sin embargo, no hubo instancias ni id's en donde se identificara algún valor duplicado.

Para finalizar esta sección, se obtuvieron los rangos de los valores en donde se revisó el mínimo y máximo de cada columna numérica. Esto con propósito de analizar que los rangos dentro de la información sean razonables y también para verificar que no existiera ningún error de captura. Gracias a esto todos los valores identificados dentro del dataframe eran consistentes con lo esperado, por ejemplo: age_years entre 0.2 y 16.0 años, weight_kg entre 2.0 y 70.6 kg, y las variables de comportamiento dentro de la escala de 0 a 10.

2.4 Transformación

Aunque se hicieron algunas transformaciones dentro del área de análisis y calidad de datos para mejorarlos. La única transformación estructural que se realizó dentro de este data frame fue la codificación de las variables categóricas. Como mencionado dentro de la sección 1.2 nuestro dataset consiste en 5 atributos categóricas las cuales son: Size, Breed_group, Intake_type,

Medical_needs y Home_type. Lamentablemente ningún algoritmo de regresión lineal puede trabajar con datos tipo texto, por lo cual para poder realizar un análisis extenso incluyendo estas columnas se realizó una transformación para convertir la información categórica en varios atributos binarios independientes. No solo eso sino, que se ingresa un 1 si pertenecía al atributo y 0 en el caso de que no.

Gracias a esto nuestra transformación expandió nuestro dataset de 32 a 48 atributos, debido a que 5 de los atributos iniciales fueron reemplazados por 21 atributos binarios. La clasificación fue la siguiente: 4 atributos para size, 7 para Breed_group, 4 para Intake_type, 3 para medical_needs, y 3 para home_type. Sin embargo, las columnas adoption_id y return_reason no fueron modificadas debido a que no forman parte de las variables numéricas utilizadas en el modelado. El tratamiento de estas variables es descrito más adelante en la sección 5.1.

2.5 Carga

Para finalizar, se elaboró la última etapa del ETL, en donde se guardan todos los cambios realizados dentro del ETL. En otras palabras, se guardaron 42,000 instancias y 48 atributos. Las cuales 46 de ellas fueron numéricas, listas para ser utilizadas en el modelo. Gracias al ETL se guardó en un nuevo archivo con el nombre de “dog_adoption_clean.csv” y va a ser la fuente de datos utilizados a partir de este punto, ya sea para el área de análisis o el modelaje.

2.6 Justificación

El ETL es un proceso sumamente importante en cualquier dataset, debido a que es una de las etapas que afecta la manera en la que se maneja la información de una manera más analítica. Sin un ETL las consecuencias se hubieran visto en etapas posteriores del proyecto ya sea en el EDA o PCA y afectaría en la manera en la que se ejecutarán.

Para empezar sin la modificación elaborada en la sección de transformación hubiera afectado en la manera en la que el modelo opera debido a que ningún tipo de modelo de regresión lineal ya sea elaborado sin frameworks o con puede operar sobre columnas de texto. Intentar entrenarlo sin esta transformación hubiera provocado errores de tipo antes de siquiera empezar el modelaje.

Para continuar, al dejar los valores nulos de `days_to_return` sin tratar hubiera propagado un NaN a cualquier cálculo posterior que incluyera este atributo. Por lo cual, se hubiera filtrado en etapas posteriores del modelo incluyendo PCA, en donde un solo valor nulo puede contagiar toda la matriz de covarianza haciéndola nula. Otra opción hubiera sido erradicar el 85% de las instancias por este atributo, sin embargo, la decisión de reemplazar el valor NaN con un 0 es mucho mejor debido a que nos ayuda a conservar nuestro dataset entero y de hecho es el valor correcto para ese atributo debido a que no hubo devolución para esos casos eso está demasiado implícito leyendo el dataframe.

Por otro lado, la revisión de los valores duplicados y los rangos numéricos fue importante debido a que aunque no hubo ningún cambio al data frame durante este proceso generó confianza en los resultados obtenidos en las secciones posteriores, reflejando los patrones reales y no artefactos repetidos o incorrectos.

Para finalizar, un dataset de este tamaño es común incluso existen datasets mil veces más grandes en la vida real. Más grandes de lo que se está trabajando en este proyecto, por lo cual hacer las correcciones de manera manual tardaría bastante tiempo sin considerar los errores que alguien pudiera realizar, sin embargo, un proceso ETL programático y reproducible hace este proceso en segundos garantizando confiabilidad en los resultados.

3. Análisis Exploratorio de Datos (EDA)

3.1 ¿Qué es el EDA?

El análisis Exploratorio de datos también conocido como el EDA por sus siglas en inglés. Es un enfoque para analizar conjuntos de datos que consiste en resumir sus características principales, frecuentemente mediante métodos visuales antes de ser aplicados en cualquier modelo estadístico. El término fue definido por Jhon Tukey en 1977 en su libro, en donde describe al EDA como una forma de dejar que los datos hablen. Por otra parte, el EDA busca en describir patrones, detectar anomalías, definir suposiciones, y generar nuevas preguntas a partir de los datos obtenidos.[6]

En la práctica el EDA involucra examinar la distribución de cada variable, identificar los valores atípicos, los cuales podrían causar errores de captura o entender la composición de las variables categóricas, y medir la relación entre variables mediante correlaciones. De hecho durante esta sección se hablará de las distribuciones, los valores atípicos, variables categóricas y las correlaciones.

El EDA cumple con el propósito de ir más allá al describir los datos, ya que es el paso en donde informa decisiones posteriores del proyecto. La importancia del EDA es que nos ayuda a validar, descartar los datos y variables presentes dentro de nuestro proyecto, las cuales nos ayudan a construir nuestro modelo.

3.2 Distribuciones

El histograma de las variables numéricas principales se muestran en la figura 3.1 y 3.2. Los atributos que cabe destacar son la de `Weight_in_kg`, `Age_years` y `Days_in_shelter`, esto debido a que tienen distribuciones sesgadas hacia la derecha, en otras palabras se significa que la mayoría de los

valores se concentran en la parte baja del rango. Esta distribución de las colas se puede interpretar como perros de mayor edad, mayor peso, o con estadías largas dentro del refugio. Por otra parte podemos observar como algunas de nuestras variables de comportamiento (Agresividad, Ansiedad, Energía, y Entrenamiento) muestran distribuciones un poco más uniformes. Sin embargo, cabe mencionar que `agresion_score` muestra el mismo sesgo hacia la derecha que los atributos anteriores refiriendo que hay bastantes perros que no exhiben agresion. Por otro lado, `anxiety separation` e incluso `reactivity_to_dogs` tienen una distribución más consistente a lo largo de su escala del 0 al 10. `Previously_returned` y `neutered` no muestran ninguna distribución debido a que son variables binarias, y la gran mayoría de los registros de `previously_returned` son 0 y 1 en `neutered`. A continuación se puede ver la figura 3.1.1 y 3.1.2 en donde se muestra la distribución de variables.




Figura 3.1.1- Distribución de las variables numéricas principales (Age_years, Weight_kg, returned, Agresion_score)




Figura 3.1.2 - Distribución de las variables numéricas principales (Days_in_shelter, Previously_returned, anxiety_separation, reactivity_to_dogs)

3.3 Valores atípicos

Para empezar, en esta sección se va a presentar los valores atípicos vistos en nuestro EDA, cabe mencionar que este tipo de valores son los datos que se alejan significativamente del resto de nuestro conjunto de datos. En este caso se planeó plantear Boxplots debido a que ayudan a visualizar estos datos de la manera más sencilla posible. Los atributos que se graficaron fueron `Age_years`, `Weight_kg` y `Days_in_shelter`. Como se puede demostrar en la figura 3.3 muestra la confirmación de la presencia de los valores atípicos (outliers) en la parte superior de cada distribución. Por ejemplo, en `Age_years` podemos observar como el rango principal de edad está entre 2 a 4 sin embargo tenemos perros con edad hasta 16 años mostrando nuestros outliers, en el caso de `Weight_kg` tiene un rango hasta 70.6kg, y la `Days_in_shelter` tiene una estancia de hasta 350 días. Aunque sean outliers y se alejen de nuestro grupo de datos principal, se tomó la decisión de no eliminar ni recortar estos valores atípicos debido a que ninguno de estos valores representa un caso biológicamente implausible para un perro real. En el caso de remover estos datos o eliminarlos causaría un

descarto de información real en lugar de eliminar el ruido.



Figura 3.2.1 - Valores atípicos Age_years




Figura 3.2.2 - Valores atípicos Weight_kg




Figura 3.2.3 - Valores atípicos Days_in_shelter

3.4 Valores Categóricos

Como ya mencionamos en la sección 1.2 de este documento, nuestro dataset cuenta con variables categóricas: Size, Breed_group, Intake_type, Medical_needs y Home_type. En la figura 3.4 se muestra el desglose de conteo por categoría en donde muestra el balance de cada una de los atributos. Como podemos observar el atributo de Size está relativamente balanceado entre medium, small y large, por el contrario podemos observar como xlarge es claramente la minoría dentro de este atributo con alrededor de 3,400 instancias. Por otra parte, en Breed_group podemos observar como está dominado por mixed con alrededor de 14,700 instancias, lo cual lo hace superar a los otros tipos de raza por casi el triple. Intake Type está dominado por stray, sin embargo, owner_surrender también representa una gran proporción de esta área. Por otro lado, en medical_needs podemos observar que está dominado por none con alrededor de 30,000 instancias superando las otras secciones por más de la mitad. Para finalizar, home_type está moderadamente inclinado hacia owned sobre apartamento o renta.




Figura 3.4.1 - Gráfica categórica (Size)




Figura 3.4.3 -Gráfica categórica (Intake_type)




Figura 3.4.2 -Gráfica categórica (Breed_group)




Figura 3.4.4 -Gráfica categórica (Medical_Needs)




Figura 3.4.5 - Gráfica categórica (Home_type)

3.5 Correlaciones

En esta sección se elaboró una matriz de correlación entre variables, esto significa que nos ayuda a visualizar si existe alguna correlación ya sea positiva o negativa entre variables. Esta matriz solo fue aplicada a las variables numéricas y durante esta sección fue en donde se verificó el hallazgo que motivó el cambio de la variable objetivo, el cual fue mencionado en la sección 1.3 Como se puede observar en la figura 3.5.1 podemos observar que ninguna variable de comportamiento tiene una correlación lineal relevante con days_in_shelter, la variable más alta es training_level con un valor de 0.23, el cual es una correlación débil que apenas explica ~5% de la varianza. Sin embargo, gracias a la matriz de correlación se pudo analizar otras correlaciones más notables como agresion_score (0.23), anxiety_separation (0.14), y reactivity_to_dogs (0.13), las cuales se asocian con la variable de returned. Es por eso, que estos atributos forman una relación más interesante que days_in_shelter, sin embargo está fuera del alcance de este

proyecto de regresión sobre el peso. En la sección posterior se analiza la correlación entre size & weight kg. La cual es nuestra variable objetivo en nuestro proyecto.




Figura 3.5 - Matriz de correlaciones entre variables numéricas.

3.6 Hallazgos clave y Justificación

Para clarificar la matriz de correlaciones de la sección 3.5 solo calcula las variables numéricas, por lo cual la variable de size no aparece en ella debido a que es una variable categórica. Sin embargo, durante la revisión de la sección 3.4 en donde hablamos de las variables categóricas, surgió una intuición a la hora de analizar los resultados obtenidos, esto se debe a que es sentido común que un perro que es clasificado como large o xlarge debería de pesar mucho más que un perro clasificado como small, esto se debe porque el tamaño y el peso están directamente conectados. Gracias a esto, al analizar que la mayoría de las correlaciones numéricas existentes tenían correlaciones débiles se decidió comparar weight_kg contra size. En este caso se realizó la comparación mediante un boxplot, esto se debe a que no se puede comparar una variable numérica con una categórica en la matriz de correlaciones. Por el

contrario, un boxplot nos ayuda a comparar ambas variables sin importar su tipo.

En este caso el hallazgo más relevante fue la asociación que existe entre ellas demostrando que la hipótesis planteada era correcta de que a mayor tamaño corresponde un peso mayor y viceversa. En la figura 3.6.1 podemos observar las 4 categorías de tamaño muestran distribuciones de peso claramente separadas e incluso podemos ver una que otra que se traslapan entre sí. Como podemos observar small tienen alrededor de ~7kg por promedio, medium ~18kg, large~30kg, y xlarge con ~45kg.




Figura 3.6.1 - Correlación entre tamaño y peso

4 Reducción de Dimensionalidad (PCA)

4.1 ¿Qué es el PCA?

El PCA o el análisis de componentes principales es una técnica que nos ayuda a la reducción de dimensionalidad que transforma un conjunto de variables numéricas, en un nuevo conjunto de variables no correlacionadas llamadas componentes principales. [7]

El objetivo principal del PCA no es solo eliminar la información, sino identificar las direcciones en las que los datos varían más. Todo esto con el propósito de representar un dataset con muchas columnas utilizando un

número menor de componentes sin perder una proporción significativa de la información real.

El PCA se calcula a partir de la matriz de covarianza, mediante una descomposición en eigenvalores y eigenvectores. Los Eigenvectores representan la dirección de un componente principal, y sus eigenvalores representan la cantidad de varianza que ese componente explica. Al ordenar los eigenvalores de mayor a menor con sus eigenvectores correspondientes nos permite determinar cuántos componentes son necesarios para determinar un porcentaje de varianza total del dataset.

Durante la elaboración de este proyecto se aplicó el PCA sobre las variables numéricas del dataset, esto con el fin de explorar la posibilidad de reducción de la dimensionalidad, esto sin perder la información relevante para el modelado. Las secciones de 4.2 a 4.4 de este documento explican la metodología, los resultados, y la interpretación de este análisis.

4.2 Justificación

Gracias al área del ETL nuestro dataset cuenta con 46 columnas numéricas. Sin embargo, antes de pasar a la etapa del modelado se realizó un análisis de componentes principales (PCA) con el objetivo de entender cuánta de la dimensionalidad es realmente necesaria. En otras palabras, cuánta de esta información redundante existe dentro de nuestros 46 atributos. Cabe aclarar que, los resultados mostrados en la sección del PCA son solo con fines exploratorios, lo que se significa que el modelo 1.0 y modelo 2.0 no utilizan los componentes principales como variables de entrada.

4.3 Metodología

Siguiendo la estructura vista en clase y referenciada dentro del curso de PCA implementado con Numpy, el procedimiento

fue el siguiente: para empezar se estandarizaron las 46 columnas numéricas a media 0 y desviación estándar 1. A continuación, se calculó la matriz de covarianza y al obtener los valores eigenvectores y eigenvalores, se ordenaron de mayor a menor y posteriormente se calculó el porcentaje de la varianza explicada por cada componente y se proyectaron los datos en un espacio de menor dimensión.

4.4 Resultados

En nuestro dataset se puede mostrar que la varianza está distribuida de una manera uniforme entre los componentes. Gracias a la figura 4.4.1 podemos ver que nuestro primer componente explica apenas 6.04% de la varianza total y para poder alcanzar el umbral de 95% de la varianza explicada se necesitan 36 de los 46 componentes.




Figura 4.4.1 - Varianza explicada individual y acumulada.

Algo que cabe observar es que en los últimos componentes de PC42 a PC46 tenemos una varianza explicada de 0%, lo cual es un resultado esperado debido a que al conservar las 5 categorías categóricas (size, breed_group, intake_type, home_type y medical_needs) sin eliminar una categoría base, hace que estos cinco grupos de columnas sumen exactamente 1 en cada fila, por lo cual introducen una dependencia lineal exacta por grupo. Gracias a PCA podemos identificar como ciertos componentes como los descritos

hace rato presentan una varianza prácticamente nula.

4.5 Interpretación

Aunque en la sección anterior pudimos ver como PC1 y PC2 explican poca varianza, se elaboró una gráfica (Figura 4.5.) para observar visualmente las agrupaciones por tamaño, las cuales están organizadas en un patrón de franjas. Los patrones de franjas son una firma característica en cuanto a las variables categóricas codificadas como binarias, en contraste si se estuviera graficando las variables numéricas se mostrará en forma de nube de puntos sin bordes definidos. Gracias a esto, podemos confirmar que size es la fuente de variación más estructurada del dataset, lo cual consiste con el hallazgo de la sección 3.6, obtenida de forma completamente independiente durante el EDA.




Figura 4.5.1 - Proyección de datos sobre los dos primeros componentes principales.

5 Modelo 1.0: Regresión lineal sin framework

5.1 Preparación de datos

5.2 Descripción del modelo

5.3 Descenso de gradiente

5.4 Entrenamiento

5.5 Resultados

5.6 Interpretaciones

5.7 Diagnóstico final

[Contexto General]
 [Gradiente descendiente]
 [Descripcion del modelo]
 [Resultados]
 [Interpretacion]
 [Diagnostico final]
 [Modelo 2.0 con framework]
 [Modelo]
 [Resultados]
 [Interpretacion]
 Diagnostico Final]
 [Mejora del modelo 1.0]
 [Criterios de evaluacion]
 [Justificacion]
 [Mejora model 2.0]
 [Conclusiones]
 [Referencias]
 [Funcion Sigmoide]
 [Funcion de costo]
 [Descenso de Gradiente]
 [Hiperparametros y parametros]
 [Funcion de prediccion]
 [Predicciones]
 [Interpretaciones]
 [Matriz de confusión?]
 [Entrenamiento]
 [Test, train y validation]
 [Evaluación del modelo 1.0]
 [Underfitting, fitting y overfitting]
 [Bias y Varianza]
 [Implementacion del framework modelo 2.0]
 [Funcionamiento del modelo 2.0]
 [Porque mejora el modelo con el framework]

- [1] <https://www.shelteranimalscount.org/shelter-animals-counts-estimation-model/>
 [2] <https://www.sciencedirect.com/science/article/abs/pii/S0957417422009083>
 [3] https://books.google.com.mx/books/about/Applied_Predictive_Modeling.html?id=xYRDAAAQBAJ
 [4] <https://www.statlearning.com/>
 [5] <https://archive.org/details/datawarehouseetl0000kimb>
 [6] https://archive.org/details/exploratorydataa0000tuke_7616
 [7] <https://link.springer.com/book/10.1007/b98835>